# Predicción de la percepción pública en X (Twitter) mediante análisis de sentimiento y aprendizaje automático

Autor:
Ing. Josmar Brazón

Director:
Mg. Ing. José David Jiménez (University of Canada West)

Codirector:
Ing. Robinson Miranda (Universidad Internacional de La Rioja)

*Esta planificación fue realizada en el curso de Gestión de proyectos entre el 26 de agosto de 2025 y el 14 de octubre de 2025.*

# Índice


**1. Descripción técnica-conceptual del proyecto a realizar** . . . . . **5**

**2. Identificación y análisis de los interesados** . . . . . **6**

**3. Propósito del proyecto** . . . . . **6**

**4. Alcance del proyecto** . . . . . **6**

**5. Supuestos del proyecto** . . . . . **7**

**6. Product Backlog** . . . . . **7**

**7. Criterios de aceptación de historias de usuario** . . . . . **8**

**8. Fases de CRISP-DM** . . . . . **12**

**9. Desglose del trabajo en tareas** . . . . . **12**

**10. Planificación de Sprints** . . . . . **17**

**11. Diagrama de Gantt (sprints)** . . . . . **29**

**12. Normativa y cumplimiento de datos (gobernanza)** . . . . . **30**

**13. Gestión de riesgos** . . . . . **30**

**14. Sprint Review** . . . . . **33**

**15. Sprint Retrospective** . . . . . **35**

## Registros de cambios

| Revisión | Detalles de los cambios realizados | Fecha |
|---|---|---|
| 0 | Creación del documento | 26 de agosto de 2025 |
| 1 | Se completa hasta el punto 5 inclusive | 9 de septiembre de 2025 |
| 2 | Se completa hasta el punto 9 inclusive | 16 de septiembre de 2025 |
| 3 | Se completa hasta el punto 12 inclusive | 23 de septiembre de 2025 |
| 4 | Se completa hasta el punto 15 inclusive | 30 de septiembre de 2025 |
| 5 | Correcciones aplicadas | 10 de octubre de 2025 |

## Acta de constitución del proyecto

Buenos Aires, 26 de agosto de 2025

Por medio de la presente se acuerda con la Ing. Josmar Brazón que su Trabajo Final de la Carrera de Especialización en Inteligencia Artificial se titulará "Predicción de la percepción pública en X (Twitter) mediante análisis de sentimiento y aprendizaje automático" y consistirá en la implementación de un prototipo de un sistema de machine learning capaz de analizar y predecir el sentimiento de la opinión pública ante eventos puntuales. El trabajo tendrá un presupuesto preliminar estimado de 600 horas y un costo estimado de 15.100.000 pesos argentinos, con fecha de inicio el 26 de agosto de 2025 y fecha de presentación pública en el mes de junio de 2026.

Se adjunta a esta acta la planificación inicial.

Dr. Ing. Ariel Lutenberg
Director posgrado FIUBA

Mg. Ing. José David Jiménez
Director del Trabajo Final

Ing. Robinson Miranda
Codirector del Trabajo Final

## 1. Descripción técnica-conceptual del proyecto a realizar

En esta sección se presenta un proyecto académico personal dentro de la Especialización en Inteligencia Artificial de la UBA (Universidad de Buenos Aires). El proyecto se desarrolla con fines exclusivamente académicos, sin acuerdos de confidencialidad ni de propiedad intelectual externos.

Inicialmente se recolectarán datos de la red social X (antes Twitter) mediante su API paga, que actualmente permite acceder al archivo completo de tuits con fines no comerciales en proyectos académicos. Posteriormente, se llevará a cabo un análisis de sentimientos y de la respuesta de los usuarios ante diferentes eventos.

El propósito principal es analizar la reacción del público en X frente a anuncios de políticas públicas locales. Se estudiarán, por ejemplo, medidas en el transporte público de Buenos Aires (cambios en el subte o en las tarifas), nuevas regulaciones ambientales y modificaciones que impacten de manera directa en el sector cultural. Posteriormente, se entrenará un modelo que sea capaz de predecir la respuesta de los usuarios ante eventos similares en el futuro.

El proceso propuesto se organiza en cuatro fases principales, que se describen a continuación y se sintetizan en la figura 1.

- Entrada de datos: recolección de tuits a través de la API de la red social X y definición de eventos relevantes, como anuncios de medidas de transporte, regulaciones ambientales u otros cambios de interés público.
- Procesamiento: limpieza y normalización de los datos recolectados con el fin de eliminar ruido y preparar la información para el análisis posterior.
- Modelado: entrenamiento de un modelo de clasificación de sentimientos que categoriza las publicaciones en positivas, negativas o neutras. Una vez entrenado, el modelo se aplica sobre tuits nuevos para predecir la reacción de los usuarios en tiempo real o frente a futuros eventos similares.
- Resultados: obtención de predicciones y métricas, que luego se visualizan en gráficos e indicadores. Esta fase final permite interpretar el comportamiento social y generar conclusiones.

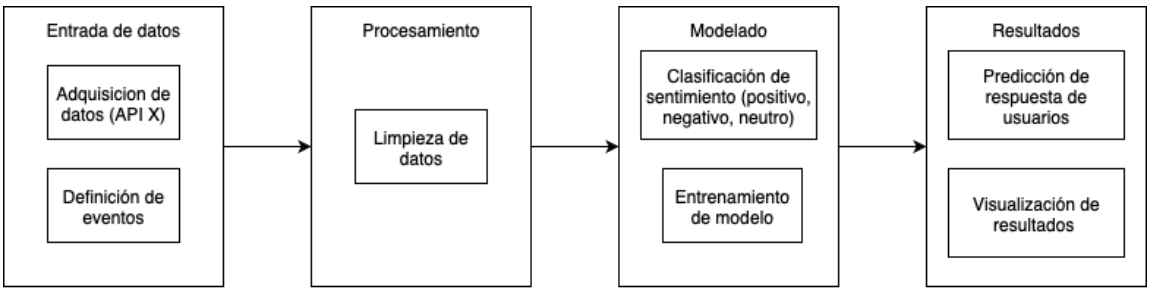


Figura 1. Diagrama en bloques del proceso.

| Rol | Nombre y Apellido | Organización | Puesto |
|---|---|---|---|
| Responsable | Ing. Josmar Brazón | FIUBA | Alumno |
| Orientador | Mg. Ing. José David Jiménez | University of Canada West | Director del Trabajo Final |
| Colaborador | Ing. Robinson Miranda | Universidad Internacional de La Rioja | Codirector del Trabajo Final |

## 2. Identificación y análisis de los interesados

- Responsable: Ing. Josmar Brazón, alumna de la carrera de Especialización en Inteligencia Artificial de la FIUBA (Facultad de Ingeniería de la Universidad de Buenos Aires), a cargo de la elaboración del proyecto final.
- Orientador: Mg. Ing. José David Jiménez cuenta con amplio conocimiento en ciencia de datos y análisis numérico, brindará apoyo en el análisis, procesamiento y modelado de datos.
- Colaborador: Ing. Robinson posee amplia experiencia en inteligencia artificial, constituye un soporte técnico fundamental.

## 3. Propósito del proyecto

Se busca diseñar, desarrollar y entrenar una herramienta de análisis que, a partir de datos históricos, permita predecir la respuesta de los usuarios en la red social X ante eventos futuros de características similares. La propuesta contempla no solo la construcción del modelo predictivo, sino también la identificación de patrones de comportamiento y tendencias relevantes, con el fin de comprender con mayor precisión la dinámica de interacción en entornos digitales.

## 4. Alcance del proyecto

El proyecto incluye:

- Análisis de la respuesta de los usuarios en la red social X.
- Análisis de la respuesta de los usuarios ante anuncios de políticas públicas locales en Buenos Aires.
  - Medidas de transporte público.
  - Regulaciones ambientales.
  - Impacto en la opinión pública ante eventos sociales o culturales.
- Evaluación de patrones de sentimiento a lo largo del tiempo.
- No se incluirá análisis de datos fuera del contexto de políticas locales de Buenos Aires.
- No se incluirá el análisis de otras redes sociales.
- No se incluirán estudios de casos individuales de usuarios concretos ni perfiles privados, el estudio se centrará en tendencias generales.
- Los datos se recopilarán de la red social X, por medio de la API o por recolección manual.

## 5. Supuestos del proyecto

Para el desarrollo del presente proyecto se supone que:

- Se contará con acceso estable a datos públicos de la red social X.
- Los datos obtenidos serán representativos del comportamiento de los usuarios en el contexto definido.
- Se asumirá consistencia en la calidad de los datos.
- Cada retuit será considerado como un nuevo registro dentro del análisis.
- No se tomarán en cuenta las interacciones de tipo "me gusta".
- Se asumirá que las publicaciones reflejan opiniones auténticas y no corresponden a actividad automatizada (bots o cuentas falsas).

## 6. Product Backlog

- **Recolección y procesamiento de datos**
  - HU1: como investigador, quiero gestionar la adquisición de la licencia de desarrollo de X y configurar el acceso a la API para poder autenticarme y recolectar datos de forma oficial y segura. (Obligatoria / Prioridad alta). Story points: 8.
  - HU2: como investigador, quiero recolectar datos de publicaciones en X relacionadas con la implementación de medidas de transporte público en la provincia de Buenos Aires para disponer de información histórica. (Obligatoria / Prioridad alta). Story points: 5.
  - HU3: como investigador, quiero recolectar datos de publicaciones en X relacionadas con la implementación de regulación de medidas ambientales en Buenos Aires para disponer de información histórica. (Obligatoria / Prioridad alta). Story points: 8.
  - HU4: como investigador, quiero recolectar datos de publicaciones en X relacionadas con la implementación de regulación de medidas culturales en Buenos Aires para disponer de información histórica. (Obligatoria / Prioridad alta). Story points: 8.
- **Análisis exploratorio y procesamiento**
  - HU5: como investigador, quiero limpiar y normalizar los datos recolectados para asegurar consistencia en el análisis. (Obligatoria / Prioridad alta). Story points: 13.
  - HU6: como analista, quiero realizar un análisis exploratorio de los datos para identificar patrones, tendencias y temas recurrentes. (Obligatoria / Prioridad alta). Story points: 4.
  - HU7: como analista, quiero modelar la polaridad de los comentarios (positiva, negativa, neutra) para medir la percepción pública. (Obligatoria / Prioridad alta). Story points: 34.
- **Predicción y modelado**
  - HU8: como científico de datos, quiero preparar conjuntos de entrenamiento, validación y prueba a partir de los datos recolectados para poder usarlos en el modelo predictivo. (Obligatoria / Prioridad alta). Story points: 4.

- HU9: como científico de datos, quiero entrenar un modelo base (Naive Bayes) para obtener una línea de referencia del desempeño. (Obligatoria / Prioridad alta). Story points: 8.
- HU10: como científico de datos, quiero entrenar un modelo robusto para mejorar la precisión de la clasificación de sentimientos. (Opcional / Prioridad media). Story points: 13.
- HU11: como científico de datos, quiero comparar los resultados entre modelos mediante métricas como presición, recall y F1 para seleccionar la opción más adecuada. (Opcional / Prioridad media). Story points: 8.
- HU12: como científico de datos, quiero optimizar el modelo elegido para maximizar su capacidad predictiva. (Opcional / Prioridad media). Story points: 5.

- **Visualización y comunicación de resultados**
  - HU13: como responsable del proyecto, quiero generar dashboards interactivos que muestren los resultados y predicciones de forma clara para facilitar la interpretación de la información. (Opcional / Prioridad media). Story points: 5.
  - HU14: como responsable del proyecto, quiero elaborar un informe final que resuma los hallazgos para facilitar la comprensión de los resultados a los destinatarios principales del proyecto. (Obligatoria / Prioridad media). Story points: 5.

## 7. Criterios de aceptación de historias de usuario

- **Épica 1**
  - Criterios de aceptación HU1
    1. La cuenta de desarrollador en X debe estar creada y habilitada.
    2. La licencia de acceso a la API debe estar vigente y registrada.
    3. El sistema debe contar con credenciales (keys y tokens) válidas para autenticarse.
    4. Se debe probar al menos un endpoint de X (ej. búsqueda de tuits) y confirmar que retorna datos.
  - Criterios de aceptación HU2
    1. Se debe recolectar información de publicaciones en X que mencionen al menos una medida de transporte público implementada en Buenos Aires (ej. cambios de tarifas, regulaciones de colectivos, subte, etc.).
    2. La recolección debe incluir como mínimo: texto de la publicación, fecha, usuario y métricas básicas de interacción (likes, reposts, comentarios).
    3. Los datos recolectados deben almacenarse en un formato estructurado (CSV) que permita su análisis posterior.
    4. La muestra inicial debe incluir al menos 500 publicaciones válidas (no duplicadas ni vacías).
    5. El proceso de recolección debe registrar la fecha de extracción y la fuente.
    6. Debe garantizarse que no existan publicaciones duplicadas y que las fechas de publicación estén normalizadas.
  - Criterios de aceptación HU3
    1. Se deben recolectar publicaciones en X que mencionen explícitamente medidas ambientales implementadas en Buenos Aires (ej. regulaciones sobre residuos, contaminación, restricciones vehiculares, etc.).

2. Cada publicación recolectada debe incluir como mínimo: texto, fecha de publicación, usuario y métricas básicas de interacción (likes, reposts, comentarios).
3. Los datos deben almacenarse en un formato estructurado (CSV) que permita su análisis posterior.
4. La muestra inicial debe incluir al menos 500 publicaciones válidas (no duplicadas ni vacías).
5. El proceso de recolección debe registrar la fecha y los términos de búsqueda utilizados.
6. Debe garantizarse que no existan publicaciones duplicadas y que las fechas de publicación estén normalizadas.

- Criterios de aceptación HU4
  1. Se deben recolectar publicaciones en X que hagan referencia explícita a regulaciones o medidas culturales implementadas en Buenos Aires (ej. festivales, acceso a espacios culturales, financiamiento, normativas sobre patrimonio, etc.).
  2. Cada publicación recolectada debe incluir como mínimo: texto, fecha de publicación, usuario y métricas básicas de interacción (likes, reposts, comentarios).
  3. Los datos deben almacenarse en un formato estructurado (CSV) que permita su análisis posterior.
  4. La muestra inicial debe incluir al menos 500 publicaciones válidas (no duplicadas ni vacías).
  5. El proceso de recolección debe registrar tanto la fecha como los términos de búsqueda utilizados.
  6. Debe garantizarse que no existan publicaciones duplicadas y que las fechas de publicación estén normalizadas.

- **Épica 2**
  - Criterios de aceptación HU5
    1. Las fechas deben estar en un formato único y consistente.
    2. Los textos deben normalizarse (las palabras deben estar libres de caracteres no reconocidos).
    3. Los textos incompletos deben identificarse y tratarse.
    4. Las categorías deben unificarse bajo un mismo criterio teniendo en cuenta al menos las siguientes: ambiental, cultural, económico y transporte.
    5. Se deben extraer y normalizar metadatos de usuario (fecha de creación, tipo de cuenta, seguidores, verificación).
    6. Las publicaciones deben vincularse correctamente con las variables de usuario generadas (ej. tipo de cuenta, antigüedad).
    7. Debe generarse un reporte que muestre los cambios aplicados durante la limpieza, normalización y enriquecimiento.
  - Criterios de aceptación HU6
    1. El análisis debe incluir estadísticas descriptivas básicas (promedios, medianas, distribuciones, máximos y mínimos).
    2. Deben generarse visualizaciones iniciales que permitan observar patrones y tendencias (histogramas, series temporales, nubes de palabras).
    3. Los datos categóricos definidos (ambiental, cultural, económico y transporte) deben ser considerados para identificar su frecuencia y relevancia.
  - Criterios de aceptación HU7

1. Los comentarios deben clasificarse manualmente en tres categorías de polaridad: positiva, negativa y neutra.
2. Solo se considerarán publicaciones y comentarios con texto válido.
3. La clasificación debe ser consistente, se aplicará el mismo criterio en todos los casos.
4. Los resultados de polaridad deben almacenarse en un formato estructurado (CSV) junto con el identificador de la publicación.
5. Debe generarse un reporte que muestre la distribución de polaridades en los datos analizados.

- **Épica 3**
  - Criterios de aceptación HU8
    1. El conjunto de datos debe dividirse en al menos tres subconjuntos: entrenamiento, validación y prueba.
    2. La proporción de la división debe estar claramente definida (ej. 80 entrenamiento, 20 validación).
    3. Los conjuntos deben conservar la representatividad de las categorías de polaridad (positiva, negativa, neutra) y de las temáticas (ambiental, cultural, económico, transporte).
    4. Los datos deben estar libres de duplicados entre los conjuntos.
    5. Debe generarse un reporte que documente el tamaño de cada conjunto, la distribución de clases y el criterio utilizado para la división.
  - Criterios de aceptación HU9
    1. El conjunto de entrenamiento, validación y prueba debe cargarse correctamente en el entorno de trabajo.
    2. El modelo debe registrar la configuración de entrenamiento (versión de dataset, features utilizadas y fecha de ejecución).
    3. El algoritmo Naive Bayes debe configurarse y ejecutarse sin errores.
    4. El modelo debe entrenarse utilizando las etiquetas de polaridad previamente clasificadas (positiva, negativa, neutra).
    5. Deben obtenerse predicciones del modelo sobre el conjunto de validación.
    6. Los resultados deben evaluarse con métricas básicas (precisión, recall, F1-score y matriz de confusión).
  - Criterios de aceptación HU10
    1. El conjunto de entrenamiento, validación y prueba debe estar correctamente preparado y cargado.
    2. Se debe seleccionar al menos un modelo más robusto que Naive Bayes (ej. Logistic Regression, SVM, Random Forest o redes neuronales básicas).
    3. El modelo debe entrenarse con las mismas etiquetas de polaridad (positiva, negativa, neutra).
    4. Se deben generar predicciones sobre el conjunto de validación.
    5. Los resultados deben compararse contra el desempeño del modelo baseline (Naive Bayes).
    6. Debe reportarse la mejora en las métricas de evaluación.
  - Criterios de aceptación HU11
    1. Los resultados de al menos dos modelos distintos deben estar disponibles para la comparación.

2. Deben calcularse de manera consistente las métricas de evaluación: precisión, recall, F1-score y matriz de confusión.
3. La comparación debe realizarse sobre el mismo conjunto de validación para asegurar equidad.
4. Debe generarse una tabla o gráfico comparativo que muestre el desempeño de cada modelo en todas las métricas.
5. El modelo con mejor desempeño global debe ser identificado como el más adecuado para continuar.
6. La comparación de modelos debe incluir al menos un gráfico que muestre el impacto de las variables sociales (tipo de usuario o antigüedad) sobre la predicción de polaridad.

- Criterios de aceptación HU12
  1. El modelo seleccionado en la comparación previa debe cargarse correctamente en el entorno de trabajo.
  2. Deben definirse los hiperparámetros relevantes del modelo (ej. regularización, profundidad de árbol, número de estimadores, tasa de aprendizaje, etc. según el algoritmo).
  3. Se aplicará una técnica de optimización de hiperparámetros (Grid Search, Random Search o validación cruzada)
  4. Los resultados optimizados deben evaluarse nuevamente en el conjunto de validación.
  5. Debe demostrarse una mejora en al menos una de las métricas principales (precisión, recall, F1-score) respecto al modelo sin optimizar.
  6. Los parámetros óptimos encontrados y los resultados finales deben documentarse en un reporte de optimización.

- **Épica 4**
  - Criterios de aceptación HU13
    1. El dashboard debe incluir visualizaciones clave sobre: distribución de polaridades (positiva, negativa, neutra), tendencias temporales y comparación de modelos.
    2. Deben mostrarse también los resultados de las predicciones generadas por el modelo final.
    3. El dashboard deberá ser interactivo, lo que permitirá filtrar por rango de fechas, categorías (ambiental, cultural, económico, transporte) y polaridad.
    4. La información presentada debe ser clara, legible y comprensible para usuarios no técnicos.
  - Criterios de aceptación HU14
    1. El informe debe incluir una descripción del objetivo del proyecto y del alcance trabajado.
    2. Debe resumir los hallazgos principales del análisis exploratorio, la clasificación manual y los modelos entrenados.
    3. El documento debe presentar de manera clara las métricas de desempeño de los modelos y la decisión final sobre el modelo elegido.
    4. Debe contener visualizaciones representativas (gráficos, tablas, dashboards exportados) que faciliten la comprensión.
    5. El informe debe estar redactado en un lenguaje accesible para público no técnico.

## 8. Fases de CRISP-DM

1. **Comprensión del negocio:** el proyecto tiene como objetivo analizar la percepción del público en torno a la implementación de políticas regulatorias en la provincia de Buenos Aires, a través de tuits en la red social X. El valor agregado de implementar técnicas de inteligencia artificial radica en la posibilidad de poder estimar la respuesta del público en futuros eventos, con identificación de patrones y tendencias de opinión. El éxito del proyecto se medirá en función a la capacidad del modelo de predecir la respuesta del público ante eventos similares en el futuro.

2. **Comprensión de los datos:** los datos a utilizar provienen de tuits, retuits y publicaciones recolectadas de la red social X, específicamente aquellos relacionados con la implementación de medidas regulatorias en Buenos Aires. Para este análisis se establecerá un volumen mínimo de 500 publicaciones por categoría.

3. **Preparación de los datos:** en esta fase se llevarán a cabo los procesos de limpieza y normalización para asegurar la consistencia de la información. Eliminación de duplicados, unificación de formatos de fecha, corrección de caracteres no reconocidos. Los tuits serán organizados manualmente en categorías temáticas (positiva, negativa, neutral) para construir un conjunto de datos confiable.

4. **Modelado:** en esta fase se aplicarán algoritmos de aprendizaje automático para no solo clasificar sentimientos en los datos históricos, sino también para predecir cómo la gente podría reaccionar ante nuevas políticas. Inicialmente con un modelo base (Naive Bayes) para tener una referencia inicial, y luego con un modelo más robusto (como regresión logística o SVM) para mejorar la precisión predictiva. El objetivo final es que el modelo, entrenado con reacciones pasadas a medidas similares, pueda anticipar la reacción del público ante futuras regulaciones.

5. **Evaluación del modelo:** en esta fase se medirá el desempeño de los modelos entrenados para determinar su capacidad predictiva. La evaluación se realizará sobre el conjunto de validación, con el cálculo de métricas estándar como precisión, recall y F1-score, además de analizar la matriz de confusión para entender los aciertos y errores de clasificación. Se compararán los resultados entre el modelo base (Naive Bayes) y los modelos más robustos, con el fin de identificar mejoras en la capacidad de predicción. Esta evaluación permitirá seleccionar el modelo más adecuado, lo que asegurará el cumplimiento de los objetivos planteados de anticipar la polaridad de los comentarios en futuras regulaciones.

6. **Despliegue del modelo:** en esta fase se presentarán los resultados del modelo seleccionado de forma clara y accesible para los destinatarios principales del proyecto. Para ello, se generarán dashboards interactivos que muestren la distribución de polaridades, tendencias a lo largo del tiempo y predicciones ante nuevas medidas regulatorias, que permitirán filtrar por categoría temática (ambiental, cultural, económico y transporte).

## 9. Desglose del trabajo en tareas

| Historia de usuario | Tarea técnica | Estimación | Prioridad |
|---|---|---|---|
| HU1 | Configurar cuenta de desarrollador en X y credenciales de acceso. | 8 h | Alta |

| Historia de usuario | Tarea técnica | Estimación | Prioridad |
|---|---|---|---|
| HU1 | Validar credenciales (keys y tokens) mediante conexión de prueba. | 4 h | Alta |
| HU1 | Probar endpoints disponibles y documentar parámetros clave. | 8 h | Alta |
| HU1 | Verificar límites de acceso y estabilidad de conexión. | 4 h | Alta |
| HU1 | Documentar flujo de autenticación y consideraciones de privacidad. | 4 h | Media |
| HU1 | Registrar incidencias o errores de conexión en bitácora técnica. | 8 h | Alta |
| HU2 | Implementar script para extracción de publicaciones de transporte. | 6 h | Alta |
| HU2 | Definir palabras clave, idioma y fechas del período de análisis. | 4 h | Alta |
| HU2 | Recolectar al menos 500 publicaciones relevantes. | 6 h | Alta |
| HU2 | Almacenar los datos en formato CSV estructurado (texto, fecha, usuario). | 6 h | Alta |
| HU2 | Verificar consistencia de los campos descargados. | 4 h | Media |
| HU2 | Documentar criterios de búsqueda y resultados obtenidos. | 2 h | Media |
| HU3 | Implementar script de extracción de publicaciones ambientales. | 6 h | Alta |
| HU3 | Definir conjunto de palabras clave y periodo temporal de búsqueda. | 4 h | Alta |
| HU3 | Recolectar un mínimo de 500 publicaciones ambientales. | 6 h | Alta |
| HU3 | Almacenar los datos en formato CSV estructurado (texto, fecha, usuario). | 6 h | Alta |
| HU3 | Validar duplicados y campos vacíos. | 4 h | Media |
| HU3 | Documentar criterios y términos de búsqueda aplicados. | 2 h | Media |
| HU4 | Implementar script de extracción de publicaciones culturales. | 6 h | Alta |
| HU4 | Definir palabras clave y filtros contextuales. | 4 h | Alta |
| HU4 | Recolectar al menos 500 publicaciones culturales. | 6 h | Alta |
| HU4 | Almacenar los datos en formato CSV estructurado (texto, fecha, usuario). | 6 h | Alta |
| HU4 | Validar integridad y formato del archivo de salida. | 4 h | Media |
| HU4 | Elaborar breve reporte descriptivo de la muestra. | 2 h | Media |
| HU5 | Diseñar proceso de normalización de texto y fechas. | 8 h | Alta |
| HU5 | Estandarizar variables (minúsculas, acentos, URLs, hashtags). | 4 h | Alta |

| Historia de usuario | Tarea técnica | Estimación | Prioridad |
|---|---|---|---|
| HU5 | Eliminar duplicados e identificar registros incompletos. | 8 h | Alta |
| HU5 | Analizar completitud, consistencia y unicidad de variables. | 4 h | Alta |
| HU5 | Generar reporte de limpieza y normalización aplicada. | 8 h | Media |
| HU5 | Incorporar variables del usuario (verificación, antigüedad, frecuencia de publicación). | 6 h | Alta |
| HU5 | Unificar categorías temáticas (ambiental, cultural, transporte, económico). | 4 h | Alta |
| HU5 | Validar coherencia de fechas y zona horaria. | 4 h | Media |
| HU5 | Evaluar outliers y valores atípicos. | 2 h | Media |
| HU6 | Generar estadísticas descriptivas (media, mediana, moda, varianza). | 8 h | Alta |
| HU6 | Analizar frecuencia de publicaciones por categoría y periodo. | 4 h | Media |
| HU6 | Identificar patrones de interacción (likes, reposts, comentarios). | 8 h | Alta |
| HU6 | Analizar correlaciones entre variables numéricas y categóricas. | 8 h | Alta |
| HU6 | Detectar multicolinealidad o redundancia de variables. | 4 h | Alta |
| HU6 | Redactar conclusiones del análisis exploratorio. | 4 h | Media |
| HU7 | Aplicar modelo o diccionario de polaridad para clasificar publicaciones. | 8 h | Alta |
| HU7 | Evaluar consistencia del modelo de polaridad. | 8 h | Alta |
| HU7 | Ajustar umbrales o reglas de decisión para mejorar precisión. | 6 h | Alta |
| HU7 | Almacenar resultados de polaridad en formato CSV. | 6 h | Media |
| HU7 | Generar reporte de distribución de polaridades. | 8 h | Media |
| HU7 | Analizar relación entre polaridad y categoría temática. | 6 h | Alta |
| HU7 | Documentar criterios y resultados de clasificación. | 4 h | Media |
| HU7 | Validar equilibrio general de polaridades por tema y tipo de usuario. | 4 h | Alta |
| HU8 | Dividir dataset en entrenamiento, validación y prueba. | 6 h | Alta |
| HU8 | Verificar representatividad por temática y polaridad. | 8 h | Alta |
| HU8 | Analizar balance de clases y estrategias de ajuste. | 6 h | Alta |

| Historia de usuario | Tarea técnica | Estimación | Prioridad |
|---|---|---|---|
| HU8 | Documentar proporciones y criterios de partición. | 8 h | Media |
| HU8 | Validar reproducibilidad mediante seed y versionado. | 4 h | Alta |
| HU8 | Verificar balance entre tipos de usuario. | 4 h | Alta |
| HU8 | Registrar configuración final de los conjuntos. | 4 h | Media |
| HU9 | Cargar datasets de entrenamiento y validación. | 8 h | Alta |
| HU9 | Entrenar modelo Naive Bayes con polaridades manuales. | 8 h | Alta |
| HU9 | Evaluar desempeño inicial con métricas de clasificación. | 8 h | Alta |
| HU9 | Analizar errores de clasificación y casos límite. | 6 h | Media |
| HU9 | Comparar precisión por temática y tipo de usuario. | 6 h | Media |
| HU9 | Registrar resultados y configuración del modelo. | 6 h | Alta |
| HU10 | Análisis y selección de modelo robusto (Logistic Regression, SVM, etc.). | 6 h | Alta |
| HU10 | Preparar pipeline de preprocesamiento y entrenamiento. | 6 h | Alta |
| HU10 | Entrenar el modelo robusto. | 8 h | Alta |
| HU10 | Evaluar desempeño en conjunto de validación. | 8 h | Alta |
| HU10 | Analizar errores y sobreajuste (overfitting/underfitting). | 6 h | Media |
| HU10 | Comparar desempeño frente a modelo baseline. | 6 h | Alta |
| HU10 | Analizar resultados por categoría y tipo de usuario. | 4 h | Media |
| HU10 | Documentar hallazgos y configuración del modelo final. | 6 h | Media |
| HU11 | Calcular métricas (precisión, recall, F1, matriz confusión). | 8 h | Alta |
| HU11 | Generar curva ROC y PR para cada modelo. | 6 h | Alta |
| HU11 | Comparar desempeño entre modelos y temáticas. | 8 h | Alta |
| HU11 | Evaluar significancia estadística de las diferencias. | 6 h | Media |
| HU11 | Generar visualizaciones comparativas. | 6 h | Media |
| HU11 | Identificar modelo con mejor desempeño global. | 4 h | Alta |
| HU11 | Redactar resumen de comparación y conclusiones. | 2 h | Media |

| Historia de usuario | Tarea técnica | Estimación | Prioridad |
|---|---|---|---|
| HU12 | Definir hiperparámetros relevantes del modelo elegido. | 6 h | Alta |
| HU12 | Ejecutar búsqueda de hiperparámetros (Grid / Random Search). | 8 h | Alta |
| HU12 | Analizar combinaciones y resultados de validación cruzada. | 8 h | Alta |
| HU12 | Evaluar desempeño post-optimización. | 6 h | Alta |
| HU12 | Comparar métricas con el modelo previo. | 4 h | Media |
| HU12 | Documentar parámetros óptimos y configuración final. | 6 h | Media |
| HU12 | Generar reporte de replicabilidad. | 6 h | Media |
| HU13 | Diseñar dashboard principal (polaridad, tendencias, comparación). | 8 h | Alta |
| HU13 | Crear visualizaciones interactivas (categoría, polaridad, fecha). | 8 h | Alta |
| HU13 | Implementar filtros dinámicos. | 8 h | Alta |
| HU13 | Evaluar claridad visual y narrativa de los datos. | 8 h | Media |
| HU13 | Ajustar estructura, colores y legibilidad. | 6 h | Alta |
| HU13 | Validar accesibilidad y carga de información. | 6 h | Media |
| HU13 | Elaborar guía de interpretación del dashboard. | 4 h | Media |
| HU14 | Redactar informe final con hallazgos y resultados. | 8 h | Alta |
| HU14 | Describir metodología de análisis y modelado. | 6 h | Alta |
| HU14 | Incluir visualizaciones más representativas. | 8 h | Media |
| HU14 | Analizar variabilidad de opiniones según perfil de usuario. | 6 h | Alta |
| HU14 | Redactar conclusiones, limitaciones y posibles mejoras. | 8 h | Media |
| HU14 | Formatear informe y exportar en PDF accesible. | 8 h | Alta |

## 10. Planificación de Sprints

| Sprint | HU o fase | Tarea | Horas / SP | Responsable | % Completado |
|---|---|---|---|---|---|
| Sprint 0 | Planificación | Definir alcance, cronograma y backlog inicial. | 10 h / 5 SP | Josmar Brazón | 100 % |
| Sprint 0 | Planificación | Reunión con tutor y revisión de objetivos. | 5 h / 3 SP | Josmar Brazón | 80 % |
| Sprint 0 | Planificación | Ajuste de entregables, repositorio y entorno. | 6 h / 3 SP | Josmar Brazón | 60 % |
| Sprint 1 | HU1 | Configurar cuenta de desarrolla-dor en X y credenciales de acceso. | 8 h / 5 SP | Josmar Brazón | 0 % |
| Sprint 1 | HU1 | Validar credenciales (keys y tokens) mediante conexión de prueba. | 4 h / 2 SP | Josmar Brazón | 0 % |
| Sprint 1 | HU1 | Probar endpoints disponibles y documentar parámetros clave. | 8 h / 5 SP | Josmar Brazón | 0 % |
| Sprint 1 | HU1 | Verificar límites de acceso y estabilidad de conexión. | 4 h / 2 SP | Josmar Brazón | 0 % |
| Sprint 1 | HU1 | Documentar flujo de au-tenticación y consideracio-nes de privacidad. | 4 h / 2 SP | Josmar Brazón | 0 % |

| | | | | | |
|---|---|---|---|---|---|
| Sprint 1 | HU1 | Registrar incidencias o errores de conexión en bitácora técnica. | 8 h / 5 SP | Josmar Brazón | 0 % |
| Sprint 2 | HU2 | Implementar script para extracción de publica-ciones de transporte. | 6 h / 3 SP | Josmar Brazón | 0 % |
| Sprint 2 | HU2 | Definir palabras clave, idioma y fechas del período de análisis. | 4 h / 2 SP | Josmar Brazón | 0 % |
| Sprint 2 | HU2 | Recolectar al menos 500 publicacio-nes relevantes. | 6 h / 3 SP | Josmar Brazón | 0 % |
| Sprint 2 | HU2 | Almacenar los datos en CSV estructurado (texto, fecha, usuario). | 6 h / 3 SP | Josmar Brazón | 0 % |
| Sprint 2 | HU2 | Verificar consistencia de los campos descargados. | 4 h / 2 SP | Josmar Brazón | 0 % |
| Sprint 2 | HU2 | Documentar criterios de búsqueda y resultados obtenidos. | 2 h / 1 SP | Josmar Brazón | 0 % |
| Sprint 3 | HU3 | Implementar script de extracción de publica-ciones ambientales. | 6 h / 3 SP | Josmar Brazón | 0 % |

| | | | | | |
|---|---|---|---|---|---|
| Sprint 3 | HU3 | Definir conjunto de palabras clave y periodo temporal de búsqueda. | 4 h / 2 SP | Josmar Brazón | 0 % |
| Sprint 3 | HU3 | Recolectar un mínimo de 500 publicaciones ambientales. | 6 h / 3 SP | Josmar Brazón | 0 % |
| Sprint 3 | HU3 | Almacenar los datos en CSV estructurado (texto, fecha, usuario). | 6 h / 3 SP | Josmar Brazón | 0 % |
| Sprint 3 | HU3 | Validar duplicados y campos vacíos. | 4 h / 2 SP | Josmar Brazón | 0 % |
| Sprint 3 | HU3 | Documentar criterios y términos de búsqueda aplicados. | 2 h / 1 SP | Josmar Brazón | 0 % |
| Sprint 4 | HU4 | Implementar script de extracción de publicaciones culturales. | 6 h / 3 SP | Josmar Brazón | 0 % |
| Sprint 4 | HU4 | Definir palabras clave y filtros contextuales. | 4 h / 2 SP | Josmar Brazón | 0 % |
| Sprint 4 | HU4 | Recolectar al menos 500 publicaciones culturales. | 6 h / 3 SP | Josmar Brazón | 0 % |

| | | | | | |
|---|---|---|---|---|---|
| Sprint 4 | HU4 | Almacenar los datos en CSV estructurado (texto, fecha, usuario). | 6 h / 3 SP | Josmar Brazón | 0 % |
| Sprint 4 | HU4 | Validar integridad y formato del archivo de salida. | 4 h / 2 SP | Josmar Brazón | 0 % |
| Sprint 4 | HU4 | Elaborar breve reporte descriptivo de la muestra. | 2 h / 1 SP | Josmar Brazón | 0 % |
| Sprint 5 | HU5 | Diseñar proceso de normalización de texto y fechas. | 8 h / 5 SP | Josmar Brazón | 0 % |
| Sprint 5 | HU5 | Estandarizar variables (minúsculas, acentos, URLs, hashtags). | 4 h / 2 SP | Josmar Brazón | 0 % |
| Sprint 5 | HU5 | Eliminar duplicados e identificar registros incompletos. | 8 h / 5 SP | Josmar Brazón | 0 % |
| Sprint 5 | HU5 | Analizar completitud, consistencia y unicidad de variables. | 4 h / 2 SP | Josmar Brazón | 0 % |
| Sprint 5 | HU5 | Generar reporte de limpieza y normalización aplicada. | 8 h / 5 SP | Josmar Brazón | 0 % |

| | | | | | |
|---|---|---|---|---|---|
| Sprint 5 | HU5 | Incorporar variables del usuario (verificación, antigüedad, frecuencia). | 6 h / 3 SP | Josmar Brazón | 0 % |
| Sprint 5 | HU5 | Unificar categorías temáticas (ambiental, cultural, transporte, económico). | 4 h / 2 SP | Josmar Brazón | 0 % |
| Sprint 5 | HU5 | Validar coherencia de fechas y zona horaria. | 4 h / 2 SP | Josmar Brazón | 0 % |
| Sprint 5 | HU5 | Evaluar outliers y valores atípicos. | 2 h / 1 SP | Josmar Brazón | 0 % |
| Sprint 6 | HU6 | Generar estadísticas descriptivas (media, mediana, varianza). | 8 h / 5 SP | Josmar Brazón | 0 % |
| Sprint 6 | HU6 | Analizar frecuencia por categoría y periodo. | 4 h / 2 SP | Josmar Brazón | 0 % |
| Sprint 6 | HU6 | Identificar patrones de interacción (likes, reposts, comentarios). | 8 h / 5 SP | Josmar Brazón | 0 % |
| Sprint 6 | HU6 | Analizar correlaciones entre variables. | 8 h / 5 SP | Josmar Brazón | 0 % |
| Sprint 6 | HU6 | Detectar multicolinealidad o redundancia. | 4 h / 2 SP | Josmar Brazón | 0 % |
| Sprint 6 | HU6 | Redactar conclusiones del EDA. | 4 h / 2 SP | Josmar Brazón | 0 % |

| | | | | | |
|---|---|---|---|---|---|
| Sprint 6 | HU7 | Aplicar modelo o diccionario de polaridad para clasificar publicaciones. | 8 h / 5 SP | Josmar Brazón | 0 % |
| Sprint 6 | HU7 | Evaluar consistencia del modelo de polaridad. | 8 h / 5 SP | Josmar Brazón | 0 % |
| Sprint 6 | HU7 | Ajustar umbrales o reglas de decisión para mejorar precisión. | 6 h / 3 SP | Josmar Brazón | 0 % |
| Sprint 6 | HU7 | Almacenar resultados de polaridad en formato CSV. | 6 h / 3 SP | Josmar Brazón | 0 % |
| Sprint 6 | HU7 | Generar reporte de distribución de polaridades. | 8 h / 5 SP | Josmar Brazón | 0 % |
| Sprint 6 | HU7 | Analizar relación entre polaridad y categoría temática. | 6 h / 3 SP | Josmar Brazón | 0 % |
| Sprint 6 | HU7 | Documentar criterios y resultados de clasificación. | 4 h / 2 SP | Josmar Brazón | 0 % |
| Sprint 6 | HU7 | Validar equilibrio de polaridades por tema y tipo de usuario. | 4 h / 2 SP | Josmar Brazón | 0 % |

| | | | | | |
|---|---|---|---|---|---|
| Sprint 7 | HU8 | Dividir dataset en entrenamiento, validación y prueba. | 6 h / 3 SP | Josmar Brazón | 0 % |
| Sprint 7 | HU8 | Verificar representatividad por temática y polaridad. | 8 h / 5 SP | Josmar Brazón | 0 % |
| Sprint 7 | HU8 | Analizar balance de clases y estrategias de ajuste. | 6 h / 3 SP | Josmar Brazón | 0 % |
| Sprint 7 | HU8 | Documentar proporciones y criterios de partición. | 8 h / 5 SP | Josmar Brazón | 0 % |
| Sprint 7 | HU8 | Validar reproducibilidad mediante seed y versionado. | 4 h / 2 SP | Josmar Brazón | 0 % |
| Sprint 7 | HU8 | Verificar balance entre tipos de usuario. | 4 h / 2 SP | Josmar Brazón | 0 % |
| Sprint 7 | HU8 | Registrar configuración final de los conjuntos. | 4 h / 2 SP | Josmar Brazón | 0 % |
| Sprint 7 | HU9 | Cargar datasets de entrenamiento y validación. | 8 h / 5 SP | Josmar Brazón | 0 % |
| Sprint 7 | HU9 | Entrenar modelo Naive Bayes con polaridades manuales. | 8 h / 5 SP | Josmar Brazón | 0 % |

| | | | | | |
|---|---|---|---|---|---|
| Sprint 7 | HU9 | Evaluar desempeño inicial con métricas de clasificación. | 8 h / 5 SP | Josmar Brazón | 0 % |
| Sprint 7 | HU9 | Analizar errores de clasificación y casos límite. | 6 h / 3 SP | Josmar Brazón | 0 % |
| Sprint 7 | HU9 | Comparar precisión por temática y tipo de usuario. | 6 h / 3 SP | Josmar Brazón | 0 % |
| Sprint 7 | HU9 | Registrar resultados y configura-ción del modelo. | 6 h / 3 SP | Josmar Brazón | 0 % |
| Sprint 8 | HU10 | Análisis y selección de modelo robusto (LogReg, SVM, etc.). | 6 h / 3 SP | Josmar Brazón | 0 % |
| Sprint 8 | HU10 | Preparar pipeline de preprocesa-miento y entrena-miento. | 6 h / 3 SP | Josmar Brazón | 0 % |
| Sprint 8 | HU10 | Entrenar el modelo robusto. | 8 h / 5 SP | Josmar Brazón | 0 % |
| Sprint 8 | HU10 | Evaluar desempeño en conjunto de validación. | 8 h / 5 SP | Josmar Brazón | 0 % |
| Sprint 8 | HU10 | Analizar errores y sobreajuste (over/underfitting). | 6 h / 3 SP | Josmar Brazón | 0 % |
| Sprint 8 | HU10 | Comparar desempeño frente a modelo baseline. | 6 h / 3 SP | Josmar Brazón | 0 % |

| | | | | | |
|---|---|---|---|---|---|
| Sprint 8 | HU10 | Analizar resultados por categoría y tipo de usuario. | 4 h / 2 SP | Josmar Brazón | 0 % |
| Sprint 8 | HU10 | Documentar hallazgos y configura-ción final. | 6 h / 3 SP | Josmar Brazón | 0 % |
| Sprint 9 | HU11 | Calcular métricas (precisión, recall, F1, matriz confusión). | 8 h / 5 SP | Josmar Brazón | 0 % |
| Sprint 9 | HU11 | Generar curva ROC y PR para cada modelo. | 6 h / 3 SP | Josmar Brazón | 0 % |
| Sprint 9 | HU11 | Comparar desempeño entre modelos y temáticas. | 8 h / 5 SP | Josmar Brazón | 0 % |
| Sprint 9 | HU11 | Evaluar significancia estadística de las diferencias. | 6 h / 3 SP | Josmar Brazón | 0 % |
| Sprint 9 | HU11 | Generar vi-sualizaciones comparati-vas. | 6 h / 3 SP | Josmar Brazón | 0 % |
| Sprint 9 | HU11 | Identificar modelo con mejor desempeño global. | 4 h / 2 SP | Josmar Brazón | 0 % |
| Sprint 9 | HU11 | Redactar resumen de comparación y conclusiones. | 2 h / 1 SP | Josmar Brazón | 0 % |

| | | | | | |
|---|---|---|---|---|---|
| Sprint 9 | HU12 | Definir hiper-parámetros relevantes del modelo elegido. | 6 h / 3 SP | Josmar Brazón | 0 % |
| Sprint 9 | HU12 | Ejecutar búsqueda de hiper-parámetros (Grid/Random Search). | 8 h / 5 SP | Josmar Brazón | 0 % |
| Sprint 9 | HU12 | Analizar combinaciones y resultados de validación cruzada. | 8 h / 5 SP | Josmar Brazón | 0 % |
| Sprint 9 | HU12 | Evaluar desempeño post-optimización. | 6 h / 3 SP | Josmar Brazón | 0 % |
| Sprint 9 | HU12 | Comparar métricas con el modelo previo. | 4 h / 2 SP | Josmar Brazón | 0 % |
| Sprint 9 | HU12 | Documentar parámetros óptimos y configuración final. | 6 h / 3 SP | Josmar Brazón | 0 % |
| Sprint 9 | HU12 | Generar reporte de replicabilidad. | 6 h / 3 SP | Josmar Brazón | 0 % |
| Sprint 10 | HU13 | Diseñar dashboard principal (polaridad, tendencias, comparación). | 8 h / 5 SP | Josmar Brazón | 0 % |
| Sprint 10 | HU13 | Crear visualizaciones interactivas (categoría, polaridad, fecha). | 8 h / 5 SP | Josmar Brazón | 0 % |

| | | | | | |
|---|---|---|---|---|---|
| Sprint 10 | HU13 | Implementar filtros dinámicos. | 8 h / 5 SP | Josmar Brazón | 0 % |
| Sprint 10 | HU13 | Evaluar claridad visual y narrativa de los datos. | 8 h / 5 SP | Josmar Brazón | 0 % |
| Sprint 10 | HU13 | Ajustar estructura, colores y legibilidad. | 6 h / 3 SP | Josmar Brazón | 0 % |
| Sprint 10 | HU13 | Validar accesibilidad y carga de información. | 6 h / 3 SP | Josmar Brazón | 0 % |
| Sprint 10 | HU13 | Elaborar guía de interpretación del dashboard. | 4 h / 2 SP | Josmar Brazón | 0 % |
| Sprint 11 | HU14 | Redactar informe final con hallazgos y resultados. | 8 h / 5 SP | Josmar Brazón | 0 % |
| Sprint 11 | HU14 | Describir metodología de análisis y modelado. | 6 h / 3 SP | Josmar Brazón | 0 % |
| Sprint 11 | HU14 | Incluir visualizaciones más representativas. | 8 h / 5 SP | Josmar Brazón | 0 % |
| Sprint 11 | HU14 | Analizar variabilidad de opiniones según perfil de usuario. | 6 h / 3 SP | Josmar Brazón | 0 % |
| Sprint 11 | HU14 | Redactar conclusiones, limitaciones y posibles mejoras. | 8 h / 5 SP | Josmar Brazón | 0 % |
| Sprint 11 | HU14 | Formatear informe y exportar en PDF accesible. | 8 h / 5 SP | Josmar Brazón | 0 % |

| | | | | | |
|---|---|---|---|---|---|
| Sprint 12 | Defensa | Preparación de presentación final y ensayo. | 17 h / 13 SP | Josmar Brazón | 0 % |

# 11. Diagrama de Gantt (sprints)

| ÉPICA | TÍTULO DE LA TAREA | DURACIÓN (HORAS) | % COMPLETADO DE LA TAREA |
|---|---|---|---|
| Planificación | Definir alcance y cronograma. | 10 | 100 % |
| Planificación | Reunión con tutor. | 5 | 50 % |
| Planificación | Ajuste de entregables y repositorio. | 6 | 0 % |
| **1** | **Recolección y procesamiento de datos** | | |
| HU1 | Configurar cuenta de desarrollador en X y credenciales de acceso. | 8 | 0 % |
| HU1 | Validar credenciales (keys y tokens) mediante conexión de prueba. | 4 | 0 % |
| HU1 | Probar endpoints disponibles y documentar parámetros clave. | 8 | 0 % |
| HU1 | Verificar límites de acceso y estabilidad de conexión. | 4 | 0 % |
| HU1 | Documentar flujo de autenticación y consideraciones de privacidad. | 4 | 0 % |
| HU1 | Registrar incidencias o errores de conexión en bitácora técnica. | 8 | 0 % |
| HU2 | Implementar script para extracción de publicaciones de transporte. | 6 | 0 % |
| HU2 | Definir palabras clave, idioma y fechas del período de análisis. | 4 | 0 % |
| HU2 | Recolectar al menos 500 publicaciones relevantes. | 6 | 0 % |
| HU2 | Almacenar los datos en formato CSV estructurado (texto, fecha, usuario). | 6 | 0 % |
| HU2 | Verificar consistencia de los campos descargados. | 4 | 0 % |
| HU2 | Documentar criterios de búsqueda y resultados obtenidos. | 2 | 0 % |
| HU3 | Implementar script de extracción de publicaciones ambientales. | 6 | 0 % |
| HU3 | Definir conjunto de palabras clave y periodo temporal de búsqueda. | 4 | 0 % |
| HU3 | Recolectar un mínimo de 500 publicaciones ambientales. | 6 | 0 % |
| HU3 | Almacenar los datos en formato CSV estructurado (texto, fecha, usuario). | 6 | 0 % |
| HU3 | Validar duplicados y campos vacíos. | 4 | 0 % |
| HU3 | Documentar criterios y términos de búsqueda aplicados. | 2 | 0 % |
| HU4 | Implementar script de extracción de publicaciones culturales. | 6 | 0 % |
| HU4 | Definir palabras clave y filtros contextuales. | 4 | 0 % |
| HU4 | Recolectar al menos 500 publicaciones culturales. | 6 | 0 % |
| HU4 | Almacenar los datos en formato CSV estructurado (texto, fecha, usuario). | 6 | 0 % |
| HU4 | Validar integridad y formato del archivo de salida. | 4 | 0 % |
| HU4 | Elaborar breve reporte descriptivo de la muestra. | 2 | 0 % |

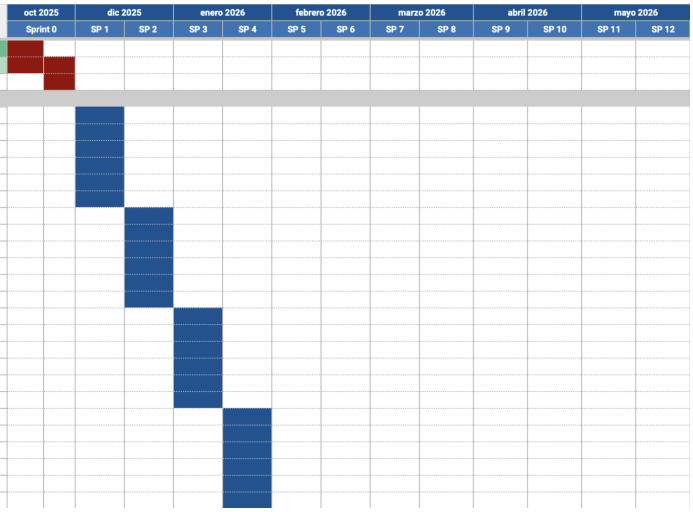


| ÉPICA | TÍTULO DE LA TAREA | DURACIÓN (HORAS) | % COMPLETADO DE LA TAREA |
|---|---|---|---|
| **2** | **Análisis exploratorio y modelado** | | |
| HU5 | Diseñar proceso de normalización de texto y fechas. | 8 | 0 % |
| HU5 | Estandarizar variables (minúsculas, acentos, URLs, hashtags). | 4 | 0 % |
| HU5 | Eliminar duplicados e identificar registros incompletos. | 8 | 0 % |
| HU5 | Analizar completitud, consistencia y unicidad de variables. | 4 | 0 % |
| HU5 | Generar reporte de limpieza y normalización aplicada. | 8 | 0 % |
| HU5 | Incorporar variables del usuario (verificación, antigüedad, frecuencia de publicación). | 6 | 0 % |
| HU5 | Unificar categorías temáticas (ambiental, cultural, transporte, económico). | 4 | 0 % |
| HU5 | Validar coherencia de fechas y zona horaria. | 4 | 0 % |
| HU5 | Evaluar outliers y valores atípicos. | 2 | 0 % |
| HU6 | Generar estadísticas descriptivas (media, mediana, moda, varianza). | 8 | 0 % |
| HU6 | Analizar frecuencia de publicaciones por categoría y periodo. | 4 | 0 % |
| HU6 | Identificar patrones de interacción (likes, reposts, comentarios). | 8 | 0 % |
| HU6 | Analizar correlaciones entre variables numéricas y categóricas. | 8 | 0 % |
| HU6 | Detectar multicolinealidad o redundancia de variables. | 4 | 0 % |
| HU6 | Redactar conclusiones del análisis exploratorio. | 4 | 0 % |
| HU7 | Aplicar modelo o diccionario de polaridad para clasificar publicaciones. | 8 | 0 % |
| HU7 | Evaluar consistencia del modelo de polaridad. | 8 | 0 % |
| HU7 | Ajustar umbrales o reglas de decisión para mejorar precisión | 6 | 0 % |
| HU7 | Almacenar resultados de polaridad en formato CSV. | 6 | 0 % |
| HU7 | Generar reporte de distribución de polaridades. | 8 | 0 % |
| HU7 | Analizar relación entre polaridad y categoría temática. | 6 | 0 % |
| HU7 | Documentar criterios y resultados de clasificación. | 4 | 0 % |
| HU7 | Validar equilibrio general de polaridades por tema y tipo de usuario. | 4 | 0 % |

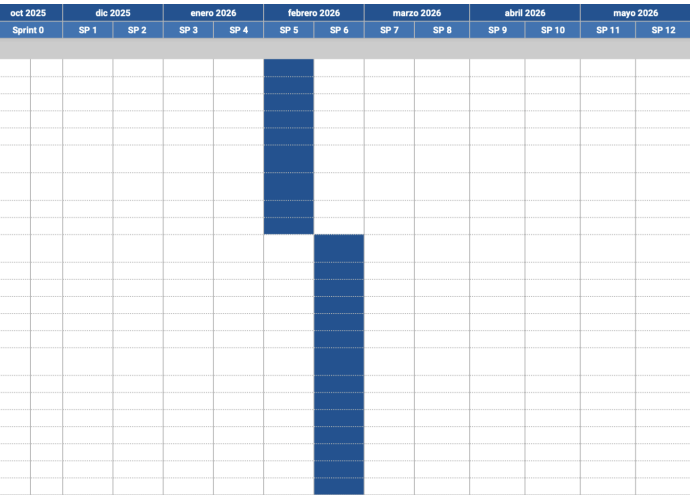


| ÉPICA | TÍTULO DE LA TAREA | DURACIÓN (HORAS) | % COMPLETADO DE LA TAREA |
|---|---|---|---|
| **3** | **Predicción y modelado** | | |
| HU8 | Dividir dataset en entrenamiento, validación y prueba. | 6 | 0 % |
| HU8 | Verificar representatividad por temática y polaridad. | 8 | 0 % |
| HU8 | Analizar balance de clases y estrategias de ajuste. | 6 | 0 % |
| HU8 | Documentar proporciones y criterios de partición. | 8 | 0 % |
| HU8 | Validar reproducibilidad mediante seed y versionado. | 4 | 0 % |
| HU8 | Verificar balance entre tipos de usuario. | 4 | 0 % |
| HU8 | Registrar configuración final de los conjuntos. | 4 | 0 % |
| HU9 | Cargar datasets de entrenamiento y validación. | 8 | 0 % |
| HU9 | Entrenar modelo Naive Bayes con polaridades manuales. | 8 | 0 % |
| HU9 | Evaluar desempeño inicial con métricas de clasificación. | 8 | 0 % |
| HU9 | Analizar errores de clasificación y casos límite. | 6 | 0 % |
| HU9 | Comparar precisión por temática y tipo de usuario. | 6 | 0 % |
| HU9 | Registrar resultados y configuración del modelo | 6 | 0 % |
| HU10 | Análisis y selección de modelo robusto (Logistic Regression, SVM, etc.). | 6 | 0 % |
| HU10 | Preparar pipeline de preprocesamiento y entrenamiento. | 6 | 0 % |
| HU10 | Entrenar el modelo robusto. | 8 | 0 % |
| HU10 | Evaluar desempeño en conjunto de validación. | 8 | 0 % |
| HU10 | Analizar errores y sobreajuste (overfitting/underfitting). | 6 | 0 % |
| HU10 | Comparar desempeño frente a modelo baseline. | 6 | 0 % |
| HU10 | Analizar resultados por categoría y tipo de usuario. | 4 | 0 % |
| HU10 | Documentar hallazgos y configuración del modelo final. | 6 | 0 % |
| HU11 | Calcular métricas (precisión, recall, F1, matriz confusión). | 8 | 0 % |
| HU11 | Generar curva ROC y PR para cada modelo. | 6 | 0 % |
| HU11 | Comparar desempeño entre modelos y temáticas. | 8 | 0 % |
| HU11 | Evaluar significancia estadística de las diferencias. | 6 | 0 % |
| HU11 | Generar visualizaciones comparativas. | 6 | 0 % |
| HU11 | Identificar modelo con mejor desempeño global. | 4 | 0 % |
| HU11 | Redactar resumen de comparación y conclusiones. | 2 | 0 % |
| HU12 | Definir hiperparámetros relevantes del modelo elegido. | 6 | 0 % |
| HU12 | Ejecutar búsqueda de hiperparámetros (Grid / Random Search). | 8 | 0 % |
| HU12 | Analizar combinaciones y resultados de validación cruzada. | 8 | 0 % |
| HU12 | Evaluar desempeño post-optimización. | 6 | 0 % |

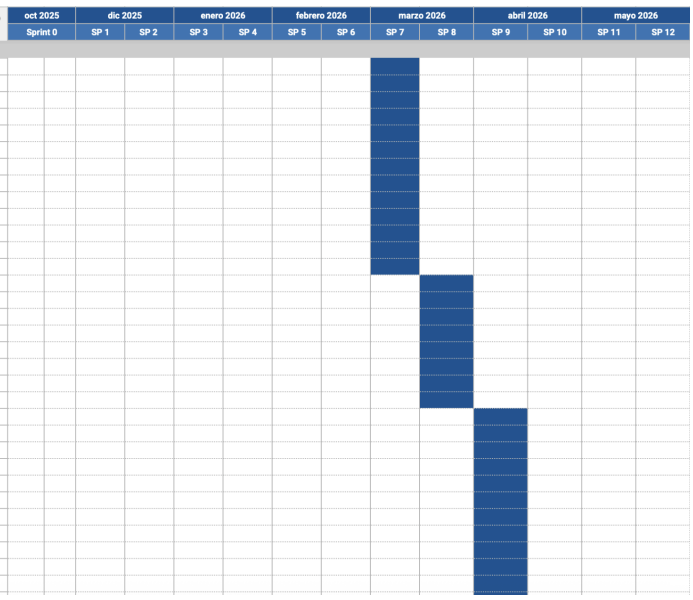

| ÉPICA | TÍTULO DE LA TAREA | DURACIÓN (HORAS) | % COMPLETADO DE LA TAREA |
|---|---|---|---|
| HU12 | Comparar métricas con el modelo previo. | 4 | 0 % |
| HU12 | Documentar parámetros óptimos y configuración final. | 6 | 0 % |
| HU12 | Generar reporte de replicabilidad. | 6 | 0 % |
| **4** | **Visualización y comunicación de resultados** | | |
| HU13 | Diseñar dashboard principal (polaridad, tendencias, comparación). | 8 | 0 % |
| HU13 | Crear visualizaciones interactivas (categoría, polaridad, fecha). | 8 | 0 % |
| HU13 | Implementar filtros dinámicos. | 8 | 0 % |
| HU13 | Evaluar claridad visual y narrativa de los datos. | 8 | 0 % |
| HU13 | Ajustar estructura, colores y legibilidad. | 6 | 0 % |
| HU13 | Validar accesibilidad y carga de información. | 6 | 0 % |
| HU13 | Elaborar guía de interpretación del dashboard. | 4 | 0 % |
| HU14 | Redactar informe final con hallazgos y resultados. | 8 | 0 % |
| HU14 | Describir metodología de análisis y modelado. | 6 | 0 % |
| HU14 | Incluir visualizaciones más representativas. | 8 | 0 % |
| HU14 | Analizar variabilidad de opiniones según perfil de usuario. | 6 | 0 % |
| HU14 | Redactar conclusiones, limitaciones y posibles mejoras. | 8 | 0 % |
| HU14 | Formatear informe y exportar en PDF accesible. | 8 | 0 % |
| Defensa | Defensa y preparación presentación final. | 17 | 0 % |

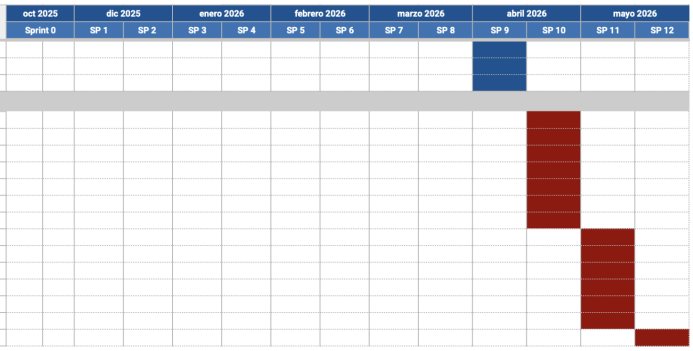


## 12. Normativa y cumplimiento de datos (gobernanza)

En el marco de este proyecto, los datos utilizados provendrán de publicaciones públicas de la red social X. Aun así, su tratamiento está sujeto a normativas de protección de datos y privacidad que deben respetarse para garantizar un uso responsable.

En Argentina, la Ley 25.326 de Protección de Datos Personales establece que, aunque se trate de información de acceso público, el uso debe regirse por principios de finalidad, proporcionalidad y seguridad. En este sentido, los datos empleados en el proyecto se utilizarán únicamente con fines académicos e investigativos, sin perseguir ningún propósito comercial ni permitir la identificación individual de los usuarios.

Asimismo, se consideran las condiciones de uso de la plataforma X, que regulan el acceso y explotación de datos a través de sus APIs oficiales. Esto implica que la recolección se realiza en conformidad con dichas políticas y evita cualquier práctica que vulnere los términos del servicio.

Ya que los datos incluirán categorías consideradas sensibles (como opiniones políticas o referencias culturales), se aplican medidas de anonimización y análisis agregado. De este modo, la investigación se centra en patrones colectivos y no en usuarios específicos.

Así, el empleo de los datos queda enmarcado en la normativa vigente y en estándares éticos de gobernanza, lo que asegura tanto la protección de la privacidad de las personas como la validez académica del estudio.

## 13. Gestión de riesgos

a) Identificación de los riesgos y estimación de sus consecuencias:

Riesgo 1: restricciones en el acceso a la API de X (Twitter).

- Severidad (S): 9.
  El proyecto depende totalmente del acceso a datos. Si la API se restringe o bloquea, el proyecto puede detenerse ya que si bien se puede recolectar datos manualmente, la cantidad de datos planificada es muy grande.
- Probabilidad de ocurrencia (O): 7.
  Las políticas de X cambian con frecuencia, lo que hace probable la limitación de acceso.

Riesgo 2: calidad insuficiente de los datos recolectados.

- Severidad (S): 8.
  Datos incompletos para las categorías planteadas en este proyecto, datos no válidos.
- Ocurrencia (O): 6.
  No existe la garantía de que las personas hablen de los tópicos planificados en este proyecto, es común que los datos de redes sociales tengan ruido, spam o bots.

Riesgo 3: fallas técnicas en el almacenamiento o procesamiento de datos.

- Severidad (S): 7.
  Una pérdida de datos implica rehacer trabajo y posibles retrasos importantes.
- Ocurrencia (O): 5.
  Es posible por errores de configuración o fallas en la infraestructura, aunque se pueden prevenir.

Riesgo 4: incumplimiento de plazos por dificultades técnicas o de coordinación.

- Severidad (S): 6.
  Un retraso afecta la entrega del proyecto, aunque no lo invalida por completo.
- Ocurrencia (O): 6.
  Es probable que surjan problemas de integración o ajustes inesperados.

Riesgo 5: bajo rendimiento del modelo predictivo.

- Severidad (S): 9.
  Si el modelo no logra una precisión aceptable, el proyecto pierde validez práctica.
- Ocurrencia (O): 5.
  Es posible, ya que depende de la calidad de datos, del ajuste de hiperparámetros y de la selección de algoritmos.

Riesgo 6: zona horaria diferente a la del director del proyecto.

- Severidad (S): 7.
  Si no llego a concretar reuniones periodicas con mi tutor, el proyecto se podría retrasar.
- Ocurrencia (O): 6.
  Es posible, ya que tenemos 5 horas de diferencia.

b) Tabla de gestión de riesgos: (El RPN se calcula como RPN=SxO)

| Riesgo | S | O | RPN | S* | O* | RPN* |
|---|---|---|---|---|---|---|
| Restricciones en la API de X | 9 | 7 | 63 | 8 | 4 | 32 |
| Calidad insuficiente de datos | 8 | 6 | 48 | 7 | 4 | 28 |
| Fallas técnicas en almacenamiento | 7 | 5 | 35 | 7 | 5 | 35 |
| Incumplimiento de plazos | 6 | 6 | 36 | 6 | 6 | 36 |
| Bajo rendimiento del modelo predictivo | 9 | 5 | 45 | 7 | 3 | 21 |
| Zona horaria diferente a la del director del proyecto | 7 | 6 | 42 | 5 | 5 | 25 |

Criterio adoptado:

Se tomarán medidas de mitigación en los riesgos cuyos números de RPN sean mayores a 40.

c) Plan de mitigación de los riesgos que originalmente excedían el RPN máximo establecido:

Riesgo 1: restricciones en el acceso a la API de X

- Plan de mitigación: utilizar fuentes de datos alternativas (datasets históricos, otras APIs) y diseñar el sistema para ser flexible.
- Severidad (S*): 8.
  Se reduce porque habría alternativas de datos, aunque siguen siendo menos completas.
- Probabilidad de ocurrencia (O*): 4.
  Menor al contar con planes de respaldo.

Riesgo 2: calidad insuficiente de datos

- Plan de mitigación: aplicar técnicas de limpieza, eliminación de spam/bots, validación de muestras y normalización de datos.
- Severidad (S*): 7.
  El impacto baja al mejorar el filtrado y preprocesamiento.
- Probabilidad (O*): 4.
  Con filtros adecuados, la ocurrencia disminuye.

Riesgo 5: bajo rendimiento del modelo predictivo

- Plan de mitigación: usar validación cruzada, comparar distintos algoritmos, y optimizar hiperparámetros.
- Severidad (S*): 7.
  Se reduce porque, incluso si un algoritmo falla, hay alternativas de modelado.
- Probabilidad de ocurrencia (O*): 3.
  Con técnicas robustas de validación, la probabilidad de bajo rendimiento disminuye.

Riesgo 5: zona horaria diferente a la del director del proyecto.

- Plan de mitigación: implementar un plan de comunicación estructurado con canales formales (correo), técnicos (reuniones) e informales (mensajería instantánea), asegurando trazabilidad en las decisiones y versiones de documentos.
- Severidad (S*): 5.
  Se reduce ya que se impulsará la comunicación por diferentes vías.
- Probabilidad de ocurrencia (O*): 5.
  La probabilidad baja dado que hay disponibilidad de ambas partes.

## 14. Sprint Review

| **HU seleccionada** | **Tareas asociadas** | **Entregable esperado** | **¿Cómo sabrás que está cumplida?** | **Observaciones o riesgos** |
|---|---|---|---|---|
| HU1: Configurar acceso a la API de X. | Configurar cuenta de desarrollador y credenciales de acceso. | Acceso habilitado y autenticado en la API. | Conexión estable y válida para la recolección de datos. | Cambios en políticas de acceso o límites de uso de X. |
| | Probar endpoints disponibles y documentar parámetros clave. | | | |

| | | | | |
|---|---|---|---|---|
| HU3: Recolectar datos ambientales. | Implementar script de extracción con filtros de palabras clave y periodo temporal. | Dataset inicial en formato .csv estructurado. | Archivo con publicaciones relevantes y limpias sobre medidas ambientales. | Datos ruidosos o presencia de spam/bots. |
| | Validar duplicados y campos vacíos en los resultados obtenidos. | | | |
| HU5: Limpiar y normalizar datos. | Estandarizar variables (minúsculas, acentos, URLs, hashtags). | Dataset limpio y consistente. | Datos aptos para análisis y modelado. | Retrasos por volumen alto o errores de formato. |
| | Incorporar variables del usuario (verificación, antigüedad, frecuencia de publicación). | | | |
| HU7: Modelar polaridad de publicaciones. | Aplicar modelo o diccionario de polaridad para clasificar publicaciones. | Reporte con distribución de polaridades. | Clasificación precisa del sentimiento (positivo, negativo, neutro). | Desbalance en los datos o errores en el modelo de polaridad. |
| | Ajustar umbrales o reglas de decisión para mejorar la precisión. | | | |

## 15. Sprint Retrospective

| Sprint tipo y N° | ¿Qué hacer más? | ¿Qué hacer menos? | ¿Qué mantener? | ¿Qué empezar a hacer? | ¿Qué dejar de hacer? |
|---|---|---|---|---|---|
| Sprint técnico - 1 | Validar de forma frecuente la conexión a la API de X y registrar logs de prueba. | Cambios en tokens o políticas de acceso sin control de versiones. | Registro de autenticaciones exitosas y respuestas válidas de los endpoints. | Documentar cada ajuste en los parámetros de configuración. | Realizar modificaciones directas sin documentar ni evaluar impacto. |
| Sprint técnico - 2 | Validar la estructura del dataset antes del análisis. | Errores al combinar archivos o campos con formatos distintos. | Confirmación de que los datos están completos y correctamente estructurados. | Registrar las verificaciones realizadas y los criterios de limpieza aplicados. | Asumir que el dataset está listo sin comprobar su consistencia. |
| Sprint técnico - 3 | Probar distintos métodos de limpieza y normalización de datos para comparar resultados. | Aceptar datos inconsistentes o sin validación. | Dataset validado con estadísticas de completitud y coherencia. | Diseñar scripts de normalización automática con control de calidad. | Corregir manualmente registros fuera de rango o con errores. |
| Sprint no técnico - 4 (Defensa final) | Ensayar la exposición con apoyo visual claro y retroalimentación de pares. | Cambiar contenidos o estructura a último momento. | Presentación fluida con transiciones naturales entre secciones. | Dividir la exposición en bloques temáticos equilibrados (contexto, método, resultados, cierre). | Sobrecargar las diapositivas con texto o gráficos innecesarios. |